

PREDICCIÓN DE TENDENCIAS DE MODA MEDIANTE MACHINE LEARNING

Proyecto de Data Science aplicado al retail de moda

Programa: Inteligencia Artificial y Data Science
Autora: Elena Cano Rogero
Ámbito: Ciencia de Datos / Machine Learning aplicado al retail
Tecnologías: Amazon S3 · AWS SageMaker Data Wrangler · SageMaker Canvas
Fecha: 26 de diciembre de 2025

Índice

APARTADO	CONTENIDO	PÁGINA
1	Contexto y motivación	3
2	Objetivo del proyecto	3
3	Datos utilizados	4
4	Exploración y análisis del dato (EDA)	5
4.1	Calidad y comprensión inicial del dato	5
4.2	Análisis de variables numéricas y categóricas	6
4.3	Distribución de la variable objetivo	6
4.4	Detección de anomalías	7
4.5	Target leakage y correlaciones	7
4.6	Sesgo y representatividad	7
5	Ingeniería de características	8
5.1	Selección y depuración de variables	8
5.2	Creación de la variable price_range	8
5.3	Tratamiento de variables categóricas	9
6	Modelado y validación	9
6.1	Importancia de las variables	10
6.2	Métricas obtenidas	10
6.3	Interpretación de los resultados	11
7	Limitaciones y trabajo futuro	11
8	Conclusiones	12

1. Contexto y motivación

La industria de la moda se caracteriza por una elevada variabilidad de la demanda. Las preferencias de los consumidores pueden cambiar rápidamente y están condicionadas por factores como la temporada, el precio, el estilo, el material o la percepción que existe sobre un determinado producto. Esta situación hace que la planificación de inventario sea especialmente compleja: comprar por encima de la demanda puede generar exceso de stock, mientras que una previsión insuficiente puede provocar roturas de existencias y pérdida de oportunidades de venta.

El análisis de datos permite transformar la información disponible sobre los productos en conocimiento útil para apoyar estas decisiones. En este proyecto se estudia si técnicas de Machine Learning pueden identificar patrones relacionados con el estado de tendencia de artículos de moda de invierno. El planteamiento se centra en analizar el problema de forma completa, desde la revisión inicial del dato hasta la interpretación de las métricas obtenidas.

El caso de uso tiene una orientación principalmente académica y experimental. El propósito no es presentar un sistema listo para producción, sino aplicar un flujo de trabajo de Data Science en un entorno cloud, documentar las decisiones realizadas y valorar de forma crítica qué información es capaz de aprender el modelo con el dataset disponible.

2. Objetivo del proyecto

El objetivo principal es desarrollar y evaluar un modelo de **clasificación multiclase** capaz de predecir el estado de tendencia de un producto de moda de invierno mediante la variable *Trend_Status*.

Para alcanzar este objetivo se plantean los siguientes objetivos específicos:

- Analizar la calidad, estructura y coherencia del dataset antes del entrenamiento.
- Explorar las variables numéricas y categóricas y estudiar su distribución.
- Revisar la distribución de *Trend_Status* y las diferencias de representación entre sus cuatro clases.
- Comprobar posibles riesgos de target leakage, correlaciones elevadas, anomalías y sesgos.
- Aplicar ingeniería de características para simplificar y mejorar la representación del conjunto.
- Entrenar un modelo de clasificación multiclase mediante AWS SageMaker Canvas.
- Evaluar accuracy, precision, recall, F1 y matriz de confusión, evitando valorar el modelo con una única métrica.
- Interpretar la importancia de las variables, reconocer las limitaciones del experimento y proponer mejoras.

3. Datos utilizados

Para realizar este proyecto utilicé el dataset [Winter Fashion Trends](#), disponible en Kaggle y publicado por Ayesha Sehrr. El conjunto contiene **150 registros y 12 variables** relacionadas con productos de moda de invierno. Incluye información numérica, como Price (USD), Popularity_Score y Customer_Rating, junto con características categóricas como Category, Color, Material, Style, Gender y Season. La variable que se desea predecir es Trend_Status.

Antes de entrenar el modelo revisé la calidad del conjunto en AWS SageMaker Data Wrangler. Esta comprobación me permitió verificar si existían valores ausentes, registros inválidos o filas duplicadas que pudieran afectar al entrenamiento.




Figura 1. Resultado del análisis de calidad del dataset en SageMaker Data Wrangler.

3.1 Calidad inicial del conjunto

El análisis confirmó que el dataset presenta **0 % de valores nulos, 100 % de registros válidos** y ausencia de filas duplicadas. Por tanto, no fue necesario realizar imputación de valores ni eliminar registros por problemas de calidad.

Esta buena calidad inicial permite continuar con el análisis exploratorio, aunque no significa que todas las variables sean igual de útiles para predecir Trend_Status. Por ello, en los siguientes apartados analizo su distribución, su relación con la variable objetivo y posibles problemas antes de entrenar el modelo.

4. Exploración y análisis del dato (EDA)


El análisis exploratorio se realizó para comprender cómo se distribuyen las variables y qué información pueden aportar al modelo. En lugar de utilizar capturas generales de toda la interfaz, se muestran únicamente los gráficos y valores que ayudan a interpretar cada variable.

4.1 Análisis de Price (USD)

El precio oscila entre **30,1 y 788 USD**, con una media aproximada de **443 USD** y una mediana cercana a **446 USD**. La distribución es relativamente equilibrada y no presenta valores perdidos ni outliers detectados por el informe.

Price(USD) - numeric

key	value
Feature name	Price(USD)
Type	numeric
Prediction power	N/A - Target column needed
Valid	100%
Missing	0%
Outliers	0%
Min	30.1
Max	788



Histogram of Price(USD).


Figura 2. Distribución de Price (USD): a la izquierda se muestran sus estadísticos y a la derecha el histograma.

4.2 Análisis de Popularity_Score

Popularity_Score toma valores entre **1,1 y 10**, con una media de **5,76** y una mediana de **5,85**. Su distribución tampoco presenta una asimetría pronunciada, por lo que no se observa una concentración extrema en un único rango.

Popularity_Score - numeric

key	value
Feature name	Popularity_Score
Min	1.1
Max	10
Mean	5.76
Median	5.85
Skew	-0.0477
Kurtosis	-1.22
Number of unique	78



Histogram of Popularity_Score.

Figura 3. Estadísticos e histograma de Popularity_Score.

4.3 Distribución de la variable objetivo

La variable **Trend_Status** contiene cuatro categorías: Outdated, Trending, Emerging y Classic. La distribución no es completamente uniforme: Outdated representa el 33,3 % de los registros, Trending el 28 %, Emerging el 20 % y Classic el 18,7 %.

Este reparto es importante porque el modelo dispone de menos ejemplos para aprender las clases minoritarias. Por este motivo, la evaluación posterior no se basa únicamente en accuracy, sino también en precision, recall, F1 y matriz de confusión.

4.4 Lectura conjunta del EDA

El análisis de las variables numéricas muestra que el conjunto no presenta problemas graves de valores extremos o datos ausentes. Las variables categóricas, por su parte, describen distintos atributos del producto: color, material, estilo, categoría, género y temporada.

En Style, por ejemplo, Sporty representa aproximadamente el 22,7 %, mientras que Formal y Streetwear alcanzan alrededor del 21,3 % cada uno. En Gender, los productos Unisex representan el 36,7 %, Women el 33,3 % y Men el 30 %. Estas diferencias son moderadas y permiten conservar las categorías para el modelado.

Variable	Lectura principal
Price (USD)	Amplio rango de precios, sin valores perdidos ni outliers detectados.
Popularity_Score	Valores repartidos entre 1,1 y 10; distribución relativamente equilibrada.
Customer_Rating	Rango entre 2,5 y 5, con media y mediana cercanas a 3,8.
Trend_Status	Cuatro clases con representación desigual; Outdated es la más frecuente.

La principal limitación detectada en esta fase no es la calidad del archivo, sino el **tamaño del dataset**. Con solo 150 observaciones repartidas entre cuatro clases, el modelo dispone de pocos ejemplos para aprender patrones sólidos y generalizables.

Esta conclusión será especialmente relevante al interpretar los resultados finales: un rendimiento moderado no debe analizarse de forma aislada, sino en relación con la cantidad de datos y la dificultad de diferenciar categorías de tendencia que pueden compartir características similares.

4.5 Target leakage y correlaciones

Antes del entrenamiento se revisó el posible *Target Leakage*. El objetivo es detectar si alguna característica contiene información que revele directa o indirectamente el valor de *Trend_Status*. Si esto ocurriera, el modelo podría obtener resultados artificialmente altos durante el entrenamiento sin generalizar correctamente a datos nuevos.



Figura 4. Análisis de Target Leakage. El recorte muestra únicamente el gráfico central utilizado para comprobar el riesgo de fuga de información.

Los valores observados no muestran una variable con capacidad predictiva anormalmente elevada que indique una fuga grave de información. También se revisaron las correlaciones entre características y no se detectaron relaciones excesivamente altas con *Trend_Status*.

4.6 Sesgo y representatividad

El Bias Report utilizó *Trend_Status* como objetivo, *Trending* como valor positivo y *Gender* como característica de análisis. Debido al reducido tamaño del dataset y a la distribución de las clases, algunas métricas no pudieron calcularse de forma concluyente.

Por tanto, el análisis no permite afirmar de manera definitiva que el conjunto esté libre de sesgo. La interpretación correcta es más prudente: **no aparecieron indicios claros de un patrón sistemático con la información disponible**, pero sería necesario un conjunto más amplio para realizar una evaluación de equidad más sólida.

5. Ingeniería de características

Las transformaciones se definieron a partir de lo observado durante el EDA. El objetivo fue eliminar información sin utilidad predictiva clara y crear variables que facilitarían la representación de los productos.

5.1 Selección y depuración de variables

Se eliminaron **ID** y **Brand**. ID es únicamente un identificador y no describe una propiedad del producto; Brand se retiró para reducir la dependencia del modelo respecto a marcas concretas y centrar el aprendizaje en atributos más generales.

5.2 Renombrado de Price (USD)

La columna Price (USD) se renombró como **price_usd** para poder utilizarla sin problemas de sintaxis al crear nuevas transformaciones con Spark SQL.




Figura 5. Renombrado de Price (USD) a price_usd dentro de Data Wrangler.

5.3 Creación de price_range

A partir del precio se creó la variable **price_range**, agrupando los productos en tres segmentos: Low para precios inferiores a 200 USD, Medium para precios inferiores a 500 USD y High para los valores restantes.



Figura 6. Resultado de la transformación price_range. La captura se centra en la nueva columna y en la fórmula aplicada.

5.4 Tratamiento de variables categóricas

Category, Style, Material, Color, Gender y Season se trataron como variables categóricas. De esta manera, el proceso de modelado puede interpretar correctamente sus categorías sin asumir que existe una relación numérica entre ellas.

6. Modelado y validación

El entrenamiento se realizó en **AWS SageMaker Canvas** utilizando Trend_Status como variable objetivo. Se eligió una tarea de clasificación multiclase porque la variable contiene cuatro estados posibles.




Figura 7. Configuración del modelo en SageMaker Canvas: Trend_Status como objetivo y Quick build como primera aproximación.

El objetivo de esta primera construcción era comprobar si las características disponibles contenían señal suficiente para diferenciar los estados de tendencia. La evaluación se realizó posteriormente con varias métricas para evitar depender de un único indicador.

Además, se descargó el notebook asociado al proceso y se intentó continuar con un training job y una fase de despliegue mediante endpoint. Esa parte no pudo completarse en el entorno académico por limitaciones de permisos, recursos o configuración, por lo que no se presentan resultados de despliegue.

6.1 Importancia de las variables

El modelo identificó **Popularity_Score** como la característica con mayor contribución, con aproximadamente un 18,2 %. **Customer_Rating** apareció a continuación con un 13,2 %, seguida de Material y Price (USD).




Figura 8. Importancia de variables mostrada por SageMaker Canvas.

Estas importancias indican qué variables utiliza con mayor peso el modelo para construir sus predicciones; no deben interpretarse como relaciones causales.

6.2 Métricas obtenidas

Los resultados obtenidos fueron:

- Accuracy $\approx$ 35,48 %
- F1 $\approx$ 26,83 %
- Precision $\approx$ 25,31 %
- Recall $\approx$ 30 %




Figura 9. Panel de métricas del modelo en SageMaker Canvas.

Los valores muestran que el modelo ha capturado algunos patrones, pero todavía presenta dificultades para separar de forma consistente las cuatro clases. Por ello, estas métricas se interpretan junto con la matriz de confusión y las limitaciones del conjunto de datos.

6.3 Interpretación de los resultados

La matriz de confusión permite complementar las métricas globales y observar en qué categorías se producen los principales aciertos y errores del modelo. Las filas representan la clase real del producto y las columnas la clase predicha.




Figura 10. Matriz de confusión del modelo obtenida en SageMaker Canvas. Los cuadros de la diagonal representan las clasificaciones correctas y el resto muestran confusiones entre categorías.

La categoría **Outdated** es la que el modelo reconoce con mayor facilidad. **Emerging** y **Trending** presentan más confusiones entre sí, mientras que **Classic** resulta especialmente difícil de identificar correctamente.

El rendimiento debe analizarse teniendo en cuenta el contexto del experimento. El dataset contiene únicamente **150 registros** y la tarea exige diferenciar cuatro clases. Como consecuencia, cada categoría dispone de pocos ejemplos para el aprendizaje y las variables disponibles no proporcionan una señal suficientemente fuerte para separar todos los estados de tendencia.

Por tanto, la accuracy del 35,48 % no se interpreta como el rendimiento de una solución preparada para producción, sino como el resultado de una primera aproximación experimental. El análisis permite identificar qué clases generan más errores y qué aspectos deberían mejorarse en una futura versión.

7. Limitaciones y trabajo futuro

La primera mejora sería **ampliar el dataset**. Un mayor número de productos permitiría disponer de más ejemplos para cada clase y comprobar si los patrones observados se mantienen. También sería conveniente estudiar estrategias para equilibrar las categorías de Trend_Status.

Otra línea de mejora consistiría en comparar diferentes algoritmos, aplicar validación cruzada y realizar ajuste de hiperparámetros. En un escenario real también sería útil incorporar variables de negocio como ventas históricas, unidades vendidas, descuentos, campañas, disponibilidad de stock o evolución temporal de la demanda.

8. Conclusiones

Este proyecto me ha permitido aplicar de forma práctica las diferentes fases de un proyecto de Machine Learning orientado al sector de la moda. He trabajado desde el análisis y preparación inicial de los datos hasta el entrenamiento y evaluación del modelo utilizando Amazon S3, SageMaker Data Wrangler y SageMaker Canvas.

El modelo obtuvo una **accuracy del 35,48 %**, un **F1 del 26,83 %**, una **precisión del 25,31 %** y un **recall del 30 %**. Aunque los resultados no son altos, me han permitido comprobar la importancia que tienen la cantidad y la calidad de los datos. En este caso, trabajar con únicamente 150 registros y cuatro categorías limita la capacidad del modelo para aprender patrones más sólidos.

La matriz de confusión también me ayudó a entender mejor los resultados. **Outdated** fue la categoría que el modelo reconoció con mayor facilidad, mientras que **Emerging** y **Trending** presentaron más confusiones y **Classic** resultó más difícil de identificar. Esto me permitió ir más allá de la accuracy y analizar dónde estaba fallando realmente el modelo.

Como continuación del proyecto, ampliaría el dataset, intentaría equilibrar mejor las clases y compararía diferentes algoritmos. También incorporaría variables más relacionadas con un entorno real de retail, como ventas históricas, stock, descuentos o evolución de la demanda. En general, el proyecto me ha servido para entender todo el proceso de Machine Learning y la importancia de interpretar los resultados y detectar qué aspectos se pueden mejorar.