

PROYECTO FINAL

Asignatura: Programa en Inteligencia Artificial y Data Science

Nombre y apellidos: Elena Cano Rogero

Fecha de entrega: 26-12-2025

INDICE

INTRODUCCIÓN:	3
OBJETIVOS DEL PROYECTO	4
PRIMEROS PASOS DEL ENTORNO DE AWS	5
DESCRIPCIÓN DEL DATASET.....	16
ANÁLISIS EXPLORATORIO DE DATOS (EDA)	17
TARGET LEAKAGE:	25
FEATURE CORRELATION:.....	27
BIAS REPORT:	29
INGENIERÍA DE CARACTERÍSTICAS	31
REALIZAR EL ENTRENAMIENTO DEL MODELO	34
CONCLUSIÓN:.....	41

INTRODUCCIÓN:

He elegido este dataset para el proyecto: [Winter Fashion Trends](#) sacado de Kaggle ya que me gusta mucho el tema. La industria de la moda, especialmente en campañas estacionales como la colección de invierno, enfrenta una gran incertidumbre respecto a la demanda real de cada producto. Tomar decisiones de inventario sin información precisa puede generar dos problemas críticos: **exceso de stock** (que implica costes de almacenamiento y pérdidas por productos no vendidos) o **roturas de stock** (pérdida directa de ventas y clientes insatisfechos).

Las empresas de retail buscan mejorar su capacidad para anticipar qué productos tendrán mayor aceptación en el mercado con el fin de planificar de forma más eficiente la producción, las compras y la distribución. En este contexto, los datos históricos relacionados con precios, popularidad, valoraciones de clientes y atributos de los productos se convierten en una fuente clave para el desarrollo de modelos predictivos que apoyen la toma de decisiones empresariales.

El caso de uso elegido consiste en **predecir la demanda de productos de moda de invierno** utilizando el dataset. Este conjunto de datos incluye información relevante sobre precios, descuentos, atributos del producto, popularidad, valoraciones de los clientes y tendencias estacionales, lo que lo convierte en una base adecuada para construir un modelo predictivo. A partir de estas variables, se busca predecir la columna *Trend_Status*, que clasifica cada producto en una de las siguientes categorías: *Outdated*, *Emerging*, *Trending* o *Classic*

La implementación de este caso de uso permitirá al negocio:

- Optimizar el nivel de inventario según la demanda estimada.
- Reducir costes asociados al sobrestock.
- Evitar roturas de stock y maximizar ventas.
- Tomar decisiones basadas en datos en lugar de intuiciones.

- Mejorar la planificación logística y de producción.

El objetivo del modelo de Machine Learning es clasificar correctamente el estado de tendencia de cada producto, permitiendo a la empresa anticiparse a la demanda del mercado y mejorar la eficiencia en la gestión del catálogo. El éxito del proyecto se mide mediante métricas de rendimiento como la precisión del modelo y su capacidad para diferenciar entre las distintas categorías de tendencia.

OBJETIVOS DEL PROYECTO

En este contexto, se plantean los siguientes objetivos para el desarrollo del presente proyecto:

Objetivo general


Desarrollar un modelo de clasificación capaz de predecir el estado de tendencia de productos de moda de invierno utilizando técnicas de Machine Learning.

Objetivos específicos


- Analizar la calidad del dataset.
- Realizar el análisis exploratorio de los datos.
- Detectar posibles fugas de información (target leakage).
- Aplicar técnicas de ingeniería de características.
- Entrenar y evaluar el modelo predictivo.

PRIMEROS PASOS DEL ENTORNO DE AWS


Voy a empezar el bucket para subir el archivo y a crear el dominio en SAGEMAKER.



En el buscador pongo: S3




Pulsó en: **crear bucket.**




En el campo “Nombre del bucket” escribí: proyectofinalenaunir y le dí a crear burcket.

Y listo ya tengo burcket creado. Pulsó en *proyectofinalelenaunir*.





Hago clic en “Cargar”, luego en “Agregar archivos” y subo el archivo **Winter_Fashion_Trends_Dataset.csv** y le doy a cargar.


Listo subido el archivo en la carpeta.




Pulso “Abrir Canvas”.



Paso 1: Para crear dominio he puesto el nombre: proyectofinalunir




Paso 2: Seleccione utilizar rol existente y hago click en el rol: LabRole.




Paso 3: En el buscador pongo: **IAM**

He copiado el ARN



Dentro del apartado de Canvas he puesto: usar el rol de ejecución y he pegado el arn. Y le he dado siguiente.





En el paso 4, personalizar IU de Studio no he hecho nada, le doy a siguiente.

En el paso 5
Establecer la
configuración de
red. He
seleccionado
acceso público a
internet.


Selecciono todas
las subredes y, en
grupo de
seguridad, marco
todas las
opciones y le doy
a siguiente.

En el paso 6,
“Configurar el
almacenamiento”,
no selecciono
nada.







En el paso 7,
“Revisar y crear”,
pulsé “Enviar”.




¡Y LISTO YA ESTÁ
EL PERFIL DE
USUARIO!!




Para crear el perfil de usuario, hago clic en “Agregar usuario”.




1 paso. En “Configuración general”, escribo elena en Nombre y le doy a “Siguiente”.




2 paso. En “Configurar aplicaciones”, entro en Canvas, copio el ARN y pulso “Siguiente”.






3 paso.

Personalizar IU de Studio no seleccionó nada y le doy a siguiente.





4 paso.

Configuración de datos y almacenamiento no seleccionó nada y le doy a siguiente.




¡Listo, ya tengo creado el perfil de usuario!




En el apartado de Notebook.

En el apartado de notebook, he pulsado y y he escrito en nombre de instancia del cuaderno: elennanotebook. Tipo de Instancia de cuaderno: ml.t3.medium.


Listo ya creado el notebook Jupyter lab.



Pulso “Abrir Canvas”.




Hago clic en “Data Wrangler”.




Pinchó en import and


prepare: Tabular.



En “Select a data source”, elijo Amazon.




Hice clic en mi dataset.



Y hago clic en “Import”.

Generé el informe de calidad de datos e insights utilizando la opción *Get data insights* en SageMaker Data Wrangler.


Seleccioné la variable *Trend_Status* como columna objetivo para el análisis, al tratarse de un problema de clasificación alineado con el caso de uso definido.



DESCRIPCIÓN DEL DATASET


Según el informe generado en SageMaker Data Wrangler:

- **Número de filas:** 150
- **Número de variables:** 12
- **Valores nulos:** 0%
- **Registros válidos:** 100%
- **Filas duplicadas:** No se detectan duplicados



ANÁLISIS EXPLORATORIO DE DATOS (EDA)

Voy hacer capturas de pantalla y explicar las gráficas.



El análisis exploratorio de datos realizado con AWS SageMaker Data Wrangler muestra que el dataset *Winter_Fashion_Trends_Dataset.csv* presenta una alta calidad, con 150 registros y 12 variables, sin valores nulos ni filas duplicadas. La variable objetivo seleccionada fue *Trend_Status*, abordando el problema como uno de clasificación. El conjunto de datos combina variables numéricas y categóricas relacionadas con precios, popularidad, valoraciones y características del producto,

lo que lo hace adecuado para un caso de uso realista en el sector de la moda. No se detectaron problemas de calidad relevantes ni indicios de *objetivo 1*, por lo que el dataset se considera apto para avanzar a la fase de ingeniería de características y al posterior entrenamiento de modelos de Machine Learning en SageMaker.

Data Wrangler: Data flow > New data flow 2025-12-26 1:44:41 PM.flow > Winter_Fashion_Trends_Dataset.csv

High Priority Warnings
No high severity warnings were detected in the data.

Feature summary
See a summary of the features.

Feature	Type	Valid	Missing	High severity warnings	Medium severity warnings
ID	numeric	100%	0%	0	0
Brand	text	100%	0%	0	0
Category	text	100%	0%	0	0
Color	text	100%	0%	0	0
Material	text	100%	0%	0	0
Style	text	100%	0%	0	0

La información está completa y es consistente. Todas las columnas presentan un **100 % de valores válidos**, por lo que no es necesario realizar tareas previas de limpieza básica.

En cuanto a los tipos de variables, el dataset combina correctamente **variables numéricas** (precio, popularidad, valoración del cliente e ID) con **variables de texto** (marca, categoría, color, material, estilo, género, temporada y estado de tendencia). No se detectan variables de tipo fecha, binario o desconocido. Además, el sistema no ha identificado **advertencias de alta prioridad**, lo que refuerza la calidad general de los datos y su idoneidad para el análisis.

El análisis se ha configurado como un problema de **clasificación**, utilizando la columna **Trend_Status** como variable objetivo *Trending*, *Outdated* o similares, y el resto de variables pueden actuar como predictores del estado de tendencia de un producto. En conjunto, el informe confirma que el dataset está bien estructurado, es fiable y puede utilizarse directamente para generar modelos predictivos o realizar análisis exploratorios sin ajustes adicionales significativos.

Data Wrangler

Duplicate rows
No duplicate rows were found in the 150 rows tested.
Note: features of type vector are ignored in duplicate rows detection

No se han encontrado registros duplicados, lo que significa que cada observación es única. Esto es importante porque evita sesgos en el análisis y en el entrenamiento del modelo, ya que los duplicados podrían influir artificialmente en los resultados. Además, se aclara que las variables de tipo vector no se tienen en cuenta en esta comprobación, aunque en este caso no afecta a la calidad global del conjunto de datos.

Anomalous samples

Canvas detects anomalous samples using the Isolation forest algorithm after basic preprocessing. The isolation forest associates an anomaly score to each sample (row) of the dataset.

- Low anomaly scores indicate anomalous samples.
- High scores are associated with non-anomalous samples.
- Samples with negative anomaly score are usually considered anomalous and samples with positive anomaly score are considered non-anomalous.

When you look at a sample that might be anomalous, we recommend that you pay attention to unusual values. For example, you might have anomalous values that result from errors in gathering and processing the data. The following is an example of the most anomalous samples according to the Canvas's implementation of the isolation forest algorithm. We recommend using domain knowledge and business logic when you examine the anomalous samples.

Anomaly scores	ID	Brand	Category	Color	Material
-0.00983	100	North Face	Thermal	Maroon	Down
-0.00292	67	North Face	Jacket	White	Down
0.00382	88	North Face	Thermal	White	Cotton
0.0116	42	North Face	Hoodie	Gray	Fleece
0.0117	29	Prada	Jacket	Black	Cashmere
0.012	32	North Face	Sweater	Black	Cashmere

Presentan **combinaciones poco frecuentes de variables** mediante el algoritmo *Isolation Forest*. Estas muestras anómalas pueden corresponder a casos extremos reales, como precios o popularidades inusuales, y no necesariamente a errores en los datos.

Feature summary

See a summary of the features.


Feature	Type	Valid	Missing	High severity warnings	Medium severity warnings
ID	numeric	100%	0%	0	0
Brand	text	100%	0%	0	0
Category	text	100%	0%	0	0
Color	text	100%	0%	0	0
Material	text	100%	0%	0	0
Style	text	100%	0%	0	0

Feature details


ID - numeric

Esta sección resume el estado de **cada variable del dataset**. Todas las características presentan un **100 % de valores válidos**, sin datos faltantes ni advertencias de severidad alta o media. Además, se identifican correctamente los

tipos de variables (numéricas y de texto), lo que confirma que los datos están bien definidos.




El análisis de *Feature Summary* muestra que todas las variables del dataset presentan un **100 % de valores válidos**, sin datos faltantes ni advertencias de severidad alta o media. Esto indica una excelente calidad de los datos y una correcta definición de los tipos de variables. En el detalle de características, se observa que la columna **IDENTIFICACIÓN** es puramente identificativa, con valores únicos y distribución uniforme, por lo que no aporta valor predictivo al modelo.




Este gráfico corresponde a una **nube de palabras** generada a partir de la columna **Brand**, que contiene las marcas de los productos del dataset. En este tipo de visualización, **el tamaño de cada palabra representa su frecuencia de aparición**: cuanto más grande es el nombre de una marca, mayor es el número de veces que aparece en los datos. Por ejemplo, marcas como *Mango*, *North Face*, *Uniqlo* o *Zara* destacan visualmente porque concentran una mayor cantidad de registros frente a otras marcas menos representadas.


Esta representación permite identificar de forma rápida la **distribución de las marcas** y detectar posibles **desbalances en la variable**, lo que es importante en fases de análisis exploratorio de datos (EDA). Si ciertas marcas dominan el dataset, el modelo podría aprender patrones más asociados a ellas, generando sesgos en las predicciones. Por tanto, este gráfico es útil tanto para comprender la composición del conjunto de datos como para tomar decisiones previas al entrenamiento del modelo, como aplicar técnicas de balanceo o selección de variables.




Este gráfico muestra la distribución de las categorías de productos a partir del análisis de texto. La nube de palabras representa las categorías más frecuentes, donde el tamaño de cada palabra es proporcional a su aparición en el dataset. Se observa que *scarf*, *thermal*, *gloves* y *sweater* son las categorías predominantes, lo que indica una clara concentración en productos de abrigo. La tabla de frecuencias refuerza esta información mostrando el porcentaje exacto de aparición de cada categoría. En conjunto, el gráfico permite identificar rápidamente los tipos de productos más representativos dentro del conjunto de datos.




La variable **Color** se analiza como una característica de tipo *text*, ya que contiene valores categóricos en formato texto sin un orden numérico. El gráfico de nube de palabras muestra los colores más frecuentes del dataset, donde el tamaño de cada palabra representa su frecuencia de aparición. Se observa que **beige**, **black** y **brown** son los colores predominantes, seguidos por tonos como **gray**, **white** y **red**. Esto indica una preferencia clara por colores neutros y clásicos en las tendencias de moda de invierno analizadas.




La variable **Material** se trata como una característica de tipo *text*, ya que recoge distintos materiales sin un orden numérico. La nube de palabras muestra los materiales más frecuentes del dataset, donde **cotton** y **fleece** destacan claramente, seguidos de **leather**, **cashmere** y **polyester**. Esto refleja una fuerte presencia de materiales cálidos y habituales en prendas de invierno, coherente con el contexto del conjunto de datos.



El gráfico muestra la distribución de los estilos de moda en el dataset. El estilo más frecuente es **sporty (22,7%)**, seguido muy de cerca por **formal** y **streetwear**, ambos con **21,3%**, lo que indica una presencia equilibrada entre estilos deportivos y urbanos/formales. **Luxury** representa un **20%**, mostrando un peso relevante de productos de gama alta. Por último, **casual** es el menos representado con **14,7%**, aunque sigue teniendo una presencia significativa en el conjunto de datos.




En la variable **Gender (texto)** se observa que los productos están dirigidos principalmente a un público **unisex**, que representa el **36,7%** del total. A continuación, los artículos para **mujeres** suponen el **33,3%**, mientras que los destinados a **hombres** alcanzan el **30%**. No hay valores perdidos y todos los datos son válidos, lo que indica una distribución bastante equilibrada entre los distintos públicos objetivo.




La variable **Season** es de tipo texto y no presenta valores perdidos (100 % de datos válidos). Todos los registros corresponden a la temporada **winter** (100 %), lo que indica que el dataset está completamente enfocado en moda de invierno. Dentro de esta temporada, los años se distribuyen principalmente en **2025 (37,3 %)**, seguido de **2024 (34,7 %)** y **2023 (28 %)**, mostrando una mayor representación de las colecciones más recientes.



El precio de los productos es una variable **numérica** sin valores perdidos ni atípicos (0% missing y 0% outliers). Los precios oscilan entre **30,1 USD** y **788 USD**, con una **media de 443 USD** y una **mediana de 446 USD**, lo que indica un nivel de precios centrado en el rango medio-alto. La **asimetría es baja** ($skew = -0,181$), por lo que la distribución es bastante equilibrada, y la **curtosis negativa (-1,02)** sugiere una distribución más plana que la normal. El histograma confirma una dispersión amplia y relativamente uniforme de precios a lo largo del rango.




El **Popularity_Score** es una variable **numérica** que mide la popularidad de los productos en una escala aproximada de **1 a 10**. En el dataset no hay valores perdidos ni atípicos (0% de *missing* y *outliers*). El valor mínimo es **1,1** y el máximo **10**, con una **media de 5,76** y una **mediana de 5,85**, lo que indica una popularidad media equilibrada. La distribución es bastante simétrica ($skew \approx -0,05$) y con colas ligeras ($kurtosis \approx -1,22$), lo que sugiere que la mayoría de los productos se concentran en valores intermedios de popularidad sin extremos muy marcados.



La valoración de los clientes oscila entre **2.5 y 5**, sin valores atípicos ni datos faltantes.


La **media y mediana son 3.8**, lo que indica una satisfacción general buena y estable.

La distribución es casi simétrica (**skew -0.06**) y con colas ligeras (**kurtosis -1.21**). Se observan **26 valores distintos**, concentrados principalmente entre **3 y 4.5** puntos.




La variable *Trend_Status* es de tipo texto y no presenta valores faltantes. El estado más frecuente es **outdated** con **33,3%**, seguido de **trending** (**28%**). En menor proporción aparecen **emerging** (**20%**) y **classic** (**18,7%**). Esto indica que una parte relevante de los productos no está en tendencia, aunque existe un peso importante de artículos actuales o en crecimiento.

TARGET LEAKAGE:



He seleccionado el tipo de problema como clasificación y he definido *Trend_Status* como la variable objetivo.



Este gráfico muestra el análisis de Target Leakage realizado con AWS SageMaker Data Wrangler. El objetivo de este análisis es detectar si alguna variable del dataset contiene información que revele directa o indirectamente el valor de la variable objetivo (*Trend_Status*), lo que podría provocar un rendimiento irrealmente alto del modelo durante el entrenamiento.


El eje horizontal representa la capacidad predictiva de cada variable medida mediante la métrica ROC. Un valor cercano a 1 indicaría una capacidad predictiva muy alta y, por tanto, una posible fuga de información (target leakage). Un valor cercano a 0.5 indica que la variable, por sí sola, no tiene capacidad predictiva relevante.

Cada línea del gráfico corresponde a una variable del dataset y está coloreada según su nivel de riesgo. Las líneas verdes indican variables seguras, es decir, que no presentan indicios de target leakage. Las líneas amarillas o rojas indicarían posibles variables problemáticas, aunque en este análisis no se observan valores críticos cercanos a 1.

En los resultados obtenidos, todas las variables presentan valores de capacidad predictiva moderados, sin alcanzar niveles que indiquen fuga de información. Esto sugiere que ninguna característica contiene información directa del *Trend_Status* que no estaría disponible en un escenario real de predicción.

En conclusión, el análisis confirma que el dataset es adecuado desde el punto de vista de target leakage y que las variables pueden utilizarse de forma segura para el entrenamiento del modelo sin riesgo de sesgo por fuga de información.

FEATURE CORRELATION:



A partir del análisis, se identifican las siguientes relaciones destacadas:

- **ID y Material** presentan la correlación más alta (~0.29), lo que no es relevante desde el punto de vista predictivo, ya que el ID no aporta información útil para el modelo.
- **Precio (USD)** muestra correlación moderada con:

- **Marca**
- **Popularidad**
- **Estilo**


Esto sugiere que el precio está relacionado con atributos del producto y su percepción en el mercado.

- **Customer Rating** presenta cierta correlación con **Brand** y **Gender**, indicando que la valoración del cliente puede variar según la marca y el público objetivo.
- La variable **Trend_Status**, que es el objetivo del modelo, muestra **correlaciones bajas** con el resto de variables, lo cual es habitual en problemas de clasificación complejos y refuerza la necesidad de utilizar modelos de Machine Learning para capturar relaciones no lineales.

El análisis de correlación permite comprobar que **no existen correlaciones excesivamente altas** entre las variables explicativas, lo cual es positivo porque reduce el riesgo de multicolinealidad. Además, confirma que la predicción del estado de tendencia (*Trend_Status*) no depende de una sola variable, sino de la combinación de múltiples características del producto.

Este análisis justifica el uso de un enfoque de **Machine Learning multivariable** para predecir las tendencias de moda de invierno de forma más precisa.

BIAS REPORT:




- **Columna objetivo (lo que predice el modelo):** Trend_Status
- **Valor que se considera positivo:** Trending
- **Columna analizada para sesgo:** Gender
- **Grupo concreto analizado:** women

He generado un Bias Report (informe de sesgo) en SageMaker Data Wrangler para analizar si el modelo presenta posibles sesgos al predecir la variable Trend_Status.

En concreto, has analizado si la predicción de que un producto sea “Trending” está influida por la variable Gender (por ejemplo, si favorece más a *women* que a otros grupos).

Los resultados del informe indican que las métricas de sesgo no pudieron calcularse de forma concluyente debido al tamaño reducido del conjunto de datos y a la distribución de las clases. No obstante, no se detectaron indicios claros de sesgo sistemático en la predicción del estado “Trending” asociado al género. Este análisis permite concluir que, con los datos disponibles, el modelo no muestra un comportamiento discriminatorio evidente.

QUICK MODEL:



- El modelo sí encuentra patrones en los datos.
- Las variables relacionadas con popularidad, precio y valoración son clave para detectar tendencias.
- El rendimiento aún es mejorable, lo cual es normal en un Quick Model.
- Sirve como validación inicial antes de entrenar modelos más avanzados con AutoML.

El Quick Model permite validar rápidamente que el conjunto de datos contiene información relevante para predecir el estado de tendencia (Trend_Status). El análisis de importancia de variables muestra que factores como la popularidad del producto, la valoración de los clientes y el precio tienen un impacto significativo en la predicción. Aunque el rendimiento inicial del modelo es moderado, los resultados confirman que el enfoque es adecuado y que el modelo podría mejorarse mediante un ajuste más avanzado o la eliminación de variables no informativas como el identificador del producto.

INGENIERÍA DE CARACTERÍSTICAS, HACER 2 TRANSFORMACIONES.

Transformación 1: Selección de columnas (quitar ID):

Voy a Eliminar: la columna **ID** y la columna **Brand** para reducir sesgos asociados a marcas reconocidas.

- **ID**: identificador único, sin valor predictivo.
- **Brand**: puede introducir **sesgo** y no es necesaria para aprender patrones generales.

Data Wrangler: Data flow > New data flow 2025-12-26 1:44:41 PM.flow > Winter_Fashion_Trends_Dataset.csv

Step 2. Data types [Chat for data prep](#) Data flow Data Analyses [Create model](#)

Build a data insights report to identify data quality issues, recommends fixes, and estimates feature importance and model accuracy. [Get data insights](#)

ID (long)	Brand (string)	Category (string)	Color (string)	Material
1 - 150	10 Categories	10 Categories	10 Categories	7 Cate
1	Adidas	Gloves	Brown	Polys
2	Gucci	Gloves	Red	Leathe
3	H&M	Coat	Brown	Fleece
4	North Face	Coat	Blue	Cashr
5	Mango	Thermal	Blue	Cashr
6	Uniqlo	Thermal	Black	Fleece

Sampling: 50,000 Columns: 12 Rows: 150 ☒ Show visualizations

Manage columns

Move, drop, duplicate or rename columns in the dataset. [Learn more](#)

Transform * [?](#)

Drop column

Columns to drop *

ID x Brand x

[Clear](#) [Preview](#) [Add](#)

Data Wrangler: Data flow > New data flow 2025-12-26 1:44:41 PM.flow > Winter_Fashion_Trends_Dataset.csv

Step 3. Drop column [Chat for data prep](#) Data flow Data Analyses [Create model](#)

Build a data insights report to identify data quality issues, recommends fixes, and estimates feature importance and model accuracy. [Get data insights](#)

Category (string)	Color (string)	Material (string)	Style (string)	Gender
10 Categories	10 Categories	7 Categories	5 Categories	3 Cate
Gloves	Brown	Polyester	Streetwear	Wome
Gloves	Red	Leather	Sporty	Men
Coat	Brown	Fleece	Streetwear	Unisex
Coat	Blue	Cashmere	Formal	Men
Thermal	Blue	Cashmere	Formal	Unisex
Thermal	Black	Fleece	Formal	Unisex

Sampling: 50,000 Columns: 10 Rows: 150 ☒ Show visualizations

Steps

[+ Add transform](#)

1. S3: Winter_Fashion_Trends_Dataset.csv

2. Data types

3. Drop column

Tengo de 12 columnas a 10 columnas.

Transformación 2: añadir una nueva columna de rangos de precio.

Data Wrangler: Data flow > New data flow 2025-12-26 1:44:41 PM.flow > Winter_Fashion_Trends_Dataset.csv

Step 3. Drop column [Chat for data prep](#)

Category (string) | Color (string) | Material (string) | Style (string) | Gender (string)

10 Categories | 10 Categories | 7 Categories | 5 Categories | 3 Categories

Category	Color	Material	Style	Gender
Gloves	Brown	Polyester	Streetwear	Woman
Gloves	Red	Leather	Sporty	Men
Coat	Brown	Fleece	Streetwear	Unisex
Coat	Blue	Cashmere	Formal	Men
Thermal	Blue	Cashmere	Formal	Unisex
Thermal	Black	Fleece	Formal	Unisex
Coat	Gray	Fleece	Casual	Men

Sampling: 50,000 | Columns: 10 | Rows: 150 | ☒ Show visualizations

Manage columns

Move, drop, duplicate or rename columns in the dataset. [Learn more.](#)

Transform *

Rename column X

Input column X

Price(USD)

New name

price_usd

Additional columns to rename

+

El error que estaba teniendo era porque **Spark SQL no reconoce Price(USD)** tal cual, ya que los paréntesis y el nombre confundían al motor. He renombrado la columna: Price (USD) a price_usd, ya que tengo error con los paréntesis al crear la formula.

He seleccionado **Custom formula**:

He puesto esto en **Formula**:

CASE

WHEN price_usd < 200 THEN 'Low'

WHEN price_usd < 500 THEN 'Medium'

ELSE 'High'

END

Y en **Output column** deja: price_range.

Data Wrangler: Data flow > New data flow 2025-12-26 1:44:41 PM.flow > Winter_Fashion_Trends_Dataset.csv

Previewing: Custom for... [Chat for data prep](#)

price_range (string) (New column) | Category (string) | Color (string) | Material (string) | Style (string)

3 Categories | 10 Categories | 10 Categories | 7 Categories | 5 Categories

price_range	Category	Color	Material	Style
Medium	Gloves	Brown	Polyester	Streetwear
Medium	Gloves	Red	Leather	Sporty
High	Coat	Brown	Fleece	Streetwear
Low	Coat	Blue	Cashmere	Formal
Low	Thermal	Blue	Cashmere	Formal
High	Thermal	Black	Fleece	Formal

Sampling: 50,000 | Columns: 11 (+1) | Rows: 150 | ☒ Show visualizations

Custom formula

Define a new column using a Spark SQL expression to query data in the current dataframe. [Learn more.](#)

Formula *

CASE WHEN price_usd < 200 THEN 'Low' WHEN price_usd < 500 THEN 'Medium' ELSE 'High' END

Output column

price_range

Clear Preview Add

Data Wrangler: Data flow > New data flow 2025-12-26 1:44:41 PM.flow > Winter_Fashion_Trends_Dataset.csv

Step 5: Custom formula

Material (string) Style (string) Gender (string) Season (string) price_usd (float) Popularity_Score (float) Customer_Rating (float) Trend_Status

Encode categorical

Convert categorical variables to numeric or vector representations. [Learn more](#)

Transform

Ordinal encode

Input columns

Category x Style x Material x Color x Gender x = 1 item selected

Advanced

Clear Preview Add

Voy a pasar de ordinal encode a categóricas. He seleccionado las columnas: Category, Style, Material, Color, Gender y Season.

Data Wrangler: Data flow > New data flow 2025-12-26 1:44:41 PM.flow > Winter_Fashion_Trends_Dataset.csv

Step 6: Ordinal encode

Category (float) Color (float) Material (float) Style (float) Gender (float) Season (float) price_usd (float) Popularity_Score (float)

Steps

- 1. S3: Winter_Fashion_Trends_Dataset.csv
- 2. Data types
- 3. Drop column
- 4. Rename column
- 5. Custom formula
- 6. Ordinal encode

Data Wrangler: Data flow > New data flow 2025-12-26 1:44:41 PM.flow

Step 6: Ordinal encode

Validation complete 0 errors

Run validation

Source

S3: Winter_Fashion_Trends_Dataset.csv

Data types

Transform: Winter_Fashion_Trends_Dataset.csv

Data Quality And Insights Report

26-12-2025, 15:24:32

Drop column

Transform: Winter_Fashion_Trends_Dataset.csv

Rename column

Transform: Winter_Fashion_Trends_Dataset.csv

Custom formula

Transform: Winter_Fashion_Trends_Dataset.csv

Ordinal encode

Transform: Winter_Fashion_Trends_Dataset.csv

REALIZAR EL ENTRENAMIENTO DEL MODELO:

Step 2: Data types

Validation complete 0 errors Done

Export to create a model

Dataset details

Dataset name *
Dataset_20251226_173132

Use only letters, numbers, spaces, dashes, colons, and underscores up to 64 characters.

☒ Process entire dataset

Model details

Model name *
Model_20251226_173132

Problem type *
Predictive analysis

Target column *
Trend_Status

Cancel Export and create model

Voy al apartado: Export and create model

My models > Model_20251226_173639 > Version 1

Select Build Analyze Predict Deploy

Select a column to predict

Choose the target column. The model that you build predicts values for the column that you select.

Target column
Trend_Status

Model type

SageMaker Canvas automatically recommends the appropriate model type for your analysis.

3+ category prediction

Your model classifies Trend_Status into 3 or more categories.

Configure model

Dataset_20251226_173639

Full dataset: 150 rows

Column name	Data type	Feature type	Missing	Mismatched	Unique	Model impact
Gender	Text	-	0.00% (0)	0.00% (0)	3	Un
Customer_Rating	123 Numeric	-	0.00% (0)	0.00% (0)	26	4.4
Color	Text	-	0.00% (0)	0.00% (0)	10	Bel
Category	Text	-	0.00% (0)	0.00% (0)	10	Sci
Brand	Text	-	0.00% (0)	0.00% (0)	10	Mi

Total columns: 10 Total rows: 150 Total cells: 1500 Show dropped columns

Model recipe

+ Add transform

Drop column ID

Drop column Brand

En **Drop column** he puesto: ID y Brand. He pinchado en Quick build.

My models > Model_20251226_173639 > Version 1

Select Build Analyze Predict Deploy

Model status Quick build

Accuracy Optimization metric

35.484%

The model predicts the correct Trend_Status 35.484% of the time.

Predict Standard build Deploy

Overview Scoring Advanced metrics

Column impact

Search columns...

Column	Impact
1 Popularity_Score	18.240%
2 Customer_Rating	13.245%
3 Material	12.233%
4 Price(USD)	12.224%

Dataset_20251226_173639 Total columns: 10 Total rows: 150 Total cells: 1500 Trend_Status 3+ category prediction

Unable to generate model reports


Canvas is unable to generate model visualizations and insights due to an issue with the Canvas server. You can continue to make predictions with the model by clicking Predict

Predict


En el modelo veo qué columnas influyen más en la predicción de Trend_Status:

1. **Popularity_Score** → 18.2%
2. **Customer_Rating** → 13.2%
3. **Material**
4. **Price (USD)**

La accuracy global del 35,48% refleja un rendimiento limitado, influido por el reducido tamaño del dataset y el desbalance entre clases.



El gráfico muestra cómo el modelo compara lo que predice con lo que ocurre realmente en los datos a la izquierda aparecen las predicciones del modelo y a la derecha los valores reales las bandas que unen ambos lados indican cuántos datos coinciden y cuántos se confunden cuanto más ancha es la banda más casos hay el modelo funciona mejor con la categoría Outdated ya que es la que más acierta y la que aparece con más frecuencia en los datos en cambio tiene más dificultades para identificar correctamente las categorías Emerging y Trending ya que muchas veces las confunde entre sí o con Outdated la categoría Classic no es bien aprendida porque el modelo no logra identificarla correctamente la precisión total del modelo es del 35 coma 48 por ciento lo que indica que acierta aproximadamente una de cada tres predicciones este resultado se debe principalmente a que el conjunto de datos es pequeño y a que algunas categorías tienen pocos ejemplos.




El modelo ha sido entrenado para predecir la variable `Trend_Status`, que clasifica los productos en distintas categorías de tendencia. La exactitud del modelo es del 35,48 %, lo que indica que el modelo acierta aproximadamente en 35 de cada 100 predicciones realizadas.

El valor de F1 promedio es del 26,83 %, lo que refleja un bajo equilibrio entre la precisión y la capacidad del modelo para identificar correctamente las clases. Este resultado sugiere que el modelo tiene dificultades para clasificar de forma consistente todas las categorías.

La precisión promedio es del 25,31 %, lo que significa que solo una cuarta parte de las predicciones positivas realizadas por el modelo son correctas. El recall promedio es del 30 %, lo que indica que el modelo solo identifica correctamente una parte limitada de los casos reales presentes en el conjunto de datos.

En conjunto, los resultados muestran que el modelo ha aprendido ciertos patrones básicos, pero su rendimiento general es bajo. Esto se debe principalmente al reducido tamaño del conjunto de datos y a la complejidad del problema al tratarse de una clasificación con múltiples categorías.



El gráfico mostrado corresponde a una **matriz de confusión** del modelo de clasificación. Las filas representan la **clase real** del producto, mientras que las columnas indican la **clase predicha** por el modelo. Los colores azules muestran las predicciones correctas, es decir, cuando el modelo acierta la categoría. Los colores rosados indican errores de clasificación, cuando el modelo confunde una categoría con otra.

La categoría **Outdated** es la que mejor reconoce el modelo, ya que presenta el mayor número de aciertos. Esto significa que el modelo identifica con mayor facilidad los productos que ya no están en tendencia.



Las categorías **Emerging** y **Trending** presentan más errores, lo que indica que el modelo tiene dificultades para diferenciarlas correctamente. La categoría **Classic** es la peor clasificada, ya que apenas se predice correctamente y suele confundirse con otras clases.

En general, el gráfico muestra que el modelo tiene un rendimiento limitado. La precisión global es baja, lo que indica que el modelo aún no aprende correctamente los patrones del conjunto de datos. Esto puede deberse al reducido número de registros y a la similitud entre algunas categorías.

Conclusión:

- El conjunto de datos contiene 150 registros y 10 variables.
- La precisión global del modelo es del 35.48%.
- La categoría mejor identificada es *Outdated*.
- Las categorías *Emerging*, *Trending* y *Classic* presentan mayor confusión.
- El rendimiento limitado se debe al tamaño reducido del dataset y a la similitud entre clases.

- El error del *Standard build* es normal en Canvas cuando el dataset es pequeño o no cumple ciertos requisitos.



En la parte derecha en los 3 puntos, he hecho click view notebook y he descargado el notebook.

Resumen del Notebook:

Durante el desarrollo del proyecto se ha trabajado con el dataset *Winter_Fashion_Trends*, que fue cargado correctamente en AWS SageMaker Data Wrangler desde Amazon S3. En primer lugar, se definió la variable objetivo **Trend_Status**, estableciendo el tipo de problema como un problema de **clasificación**, ya que el objetivo del modelo es predecir el estado de tendencia de cada producto dentro de varias categorías posibles.


A continuación, se realizó un análisis exploratorio de los datos mediante el **Data Quality and Insights Report**, cuyos resultados mostraron que el conjunto de datos presenta una buena calidad general. No se detectaron valores nulos, filas duplicadas ni errores críticos, lo que indica que los datos son consistentes y adecuados para el entrenamiento de un modelo de Machine Learning.

Posteriormente, se llevó a cabo el análisis de **Target Leakage** para comprobar si alguna de las variables predictoras contenía información que pudiera anticipar directamente el valor de la variable objetivo. El análisis indicó que no existe una fuga de información grave, por lo que el dataset puede utilizarse con seguridad para el entrenamiento del modelo. Algunas variables mostraron menor capacidad predictiva individual, pero sin comprometer la validez del proceso.


En la fase de **ingeniería de características**, se eliminaron columnas que no aportaban valor predictivo, como identificadores o marcas, y se transformaron varias columnas de tipo texto, como *Category*, *Style*, *Material*, *Color*, *Gender* y *Season*, a variables categóricas. Esta transformación permite que los algoritmos de Machine Learning interpreten correctamente estas características y mejora la calidad del entrenamiento.

También se intentó ejecutar el análisis de **Feature Correlation** para estudiar la relación entre las variables, aunque en algunos momentos este proceso se vio afectado por limitaciones internas de la plataforma, como tareas en cola o tiempos de espera elevados. Estos errores no están relacionados con la calidad de los datos ni con el trabajo realizado, y no impiden continuar con el proyecto.


Finalmente, el flujo de datos fue validado correctamente sin errores y el dataset quedó preparado para su exportación y uso en el entrenamiento del modelo. En este punto, el proyecto se encuentra listo para avanzar a la siguiente fase, que consiste en el **entrenamiento del modelo utilizando AWS SageMaker Autopilot o SageMaker Canvas**, así como su posterior evaluación y despliegue.



Para descargar en Python: ve a Data Types → Export → Export via Jupyter Notebook → Python code, y se descargará el archivo.



Dentro de notebooklab, he descargado el notebook



Primero, en la parte superior, se intenta **lanzar el entrenamiento del modelo**. Ahí aparece el mensaje “*Creating Training Job...*”, lo que significa que SageMaker está intentando crear un **training job** en la nube con los datos y parámetros definidos previamente. Sin embargo, en tu caso aparece un **error en rojo**, lo que indica que **el entrenamiento no se ha completado correctamente**. Esto suele ocurrir por problemas de permisos, recursos, configuración automática o límites del entorno del laboratorio.

Después, más abajo, aparece la sección de **Model Deployment**. Esa parte del código sirve para **desplegar el modelo entrenado como un endpoint**, es decir, dejarlo disponible para hacer predicciones en tiempo real.

CONCLUSIÓN:

En este proyecto se ha desarrollado un caso práctico de Machine Learning aplicado al sector del retail de moda, utilizando el dataset [Winter Fashion Trends](#) en kaggle y las herramientas de AWS SageMaker Canvas y Data Wrangler. El objetivo principal ha sido predecir el estado de tendencia de productos de moda de invierno mediante la variable **Trend_Status**, abordando el problema como una tarea de clasificación multiclase.

A lo largo del trabajo se ha realizado un proceso completo de análisis de datos, comenzando por la carga y validación del dataset en Amazon S3 y SageMaker. El análisis de calidad de datos ha confirmado que el conjunto de datos presenta una excelente consistencia, sin valores nulos ni duplicados, lo que ha permitido avanzar directamente a las fases de análisis exploratorio e ingeniería de características sin necesidad de limpieza adicional.

Los análisis de **Target Leakage** y **Feature Correlation** han demostrado que no existen fugas de información ni relaciones excesivamente fuertes entre variables que pudieran comprometer la validez del modelo. Esto refuerza la fiabilidad del dataset y justifica el uso de un enfoque de Machine Learning para capturar patrones complejos entre múltiples características. Asimismo, el **Bias Report** no ha evidenciado sesgos claros asociados al género en la predicción de productos “Trending”, aunque se reconoce que el tamaño reducido del dataset limita la capacidad de obtener conclusiones definitivas en este aspecto.

En la fase de ingeniería de características se aplicaron transformaciones relevantes, como la eliminación de variables sin valor predictivo (ID y Brand), la creación de una nueva variable de rangos de precio y la conversión de variables textuales a categóricas. Estas decisiones mejoraron la preparación del dataset para el entrenamiento del modelo y reflejan buenas prácticas en proyectos de ciencia de datos.

El modelo entrenado mediante SageMaker Canvas alcanzó una **precisión global del 35,48 %**, con un mejor desempeño en la categoría *Outdated* y mayores dificultades para diferenciar entre *Emerging*, *Trending* y *Classic*. Este rendimiento limitado se explica principalmente por el tamaño reducido del conjunto de datos y el desbalance entre clases, lo que restringe la capacidad del modelo para generalizar correctamente. Aun así, el modelo logró identificar patrones básicos y permitió analizar la importancia relativa de variables como *Popularity_Score* y *Customer_Rating*.

En conjunto, el proyecto demuestra la viabilidad de aplicar técnicas de Machine Learning para apoyar la toma de decisiones en la industria de la moda, incluso utilizando herramientas *no-code* como SageMaker Canvas.